# 109550035 楊賀弼

## GitHub link

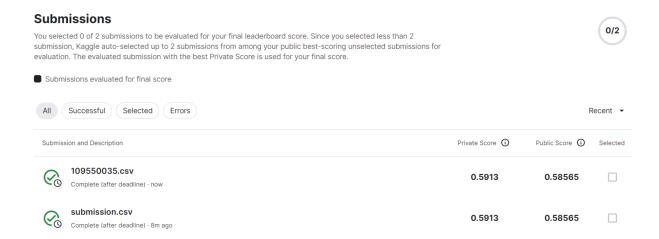
https://github.com/behebiiii/ML-Project

## Model link

Model.pkl

https://drive.google.com/file/d/11gyniZNc9GogyBesy8P7BQPZbblGEnOE/view?usp=sharing

# Screenshot of my submissions



## • Reference:

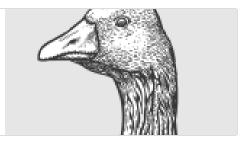
1.

#### TPSAUG22 EDA which makes sense \*\*\*



Explore and run machine learning code with Kaggle Notebooks | Using data from Tabular Playground Series - Aug 2022

k https://www.kaggle.com/code/ambrosm/tpsaug22-eda-which-ma kes-sense#Product-codes-and-attributes



2.

#### LB 0.58978 Standing on the shoulder of giants

Explore and run machine learning code with Kaggle Notebooks | Using data from Tabular Playground Series - Aug 2022

k https://www.kaggle.com/code/maxsarmento/lb-0-58978-standin g-on-the-shoulder-of-giants?scriptVersionId=102785631



### Brief introduction

針對這次作業我是用 Logistic Regression 的方式去實做的,在一開始的時候,我是有先 參考 Reference 1 的內容(EDA),去看說 這份資料集的內容到底是甚麼,然後才開始去 實作內容。

在第一次做完成功的預測之後,分數還沒達到baseline,所以我就上討論區看看大家都怎 麼去improve的,所以我就看到 Reference 2 的文章,可以再利用 再加上 hidden features 來去把準確率提高。

詳細實作內容我有寫在註解裡。

## Methodology

## 資料前處理,將所有特徵標準化

scaler = RobustScaler()

因為看了 Reference 1 的分析 對於 attribute對failure的關西,只有 attribute 0.1比較重 要,因為他們不是float 或是 int 所以做 one-hot encoded。

```
# one-hot encoded
Xt = pd.get_dummies(X_train, columns=['attribute_0'])
Xt.drop(["attribute_1"], axis=1, inplace=True)
```

再來就是必須把資料裡有空缺的補上,且針對不同的類別做不同的估測。

```
for feature in X_columns:
    if X_train[feature].dtype == "float":
        Xt[feature].fillna((X_train[feature].mean()), inplace=True)
    if X_train[feature].dtype == "object":
        Xt[feature].fillna((X_train[feature].mode()), inplace=True)
    if X_train[feature].dtype == "int":
        Xt[feature].fillna((X_train[feature].median()), inplace=True)
```

#### 最後再做標準化

```
Xt= scaler.fit_transform(Xt)
```

#### Model

model 是用 Logistic Regression

```
model = LogisticRegression()
```

再利用 Grid Search 去調到 best parameters

clf = GridSearchCV(model, param\_grid = param\_grid, cv = 5, verbose=True, n\_jobs=-1)
best\_clf = clf.fit(Xt, y\_train.values.ravel())

# Summary

做完這份作業後,我才了解到在做ML時對於資料集的分析是非常重要的,做預測並不難,但是你要找到對於預測有幫助的feature比較重要,其實也有一大部分時間是在看討論區裡面的人他們是怎麼發現,怎麼去找到這些可以去增進正確率的方式。也讓我了解到之後再面對這種feature一大堆的資料時,更可以知道怎麼下手。